Sprawozdanie PJN lab1

Karol Kapusta, Paweł Kosiński

1. Użyta technologia

Strona WWW

Serwis zbudowano jako statyczne pliki **HTML**, **Bootstrap** i **JavaScript**. Dane produktów są przechowywane w jednym pliku **JSON**. Taki układ jest prosty do uruchomienia lokalnie, rozdziela treść od prezentacji i pozwala zmieniać listę produktów bez ręcznego powielania rekordów w plikach HTML.

Parser

- **Python** – używany do pobierania, parsowania HTML, normalizacji, analizy statystycznej i eksportu.
- **Playwright z Microsoft Edge** - wykonuje JavaScript serwisu, obsługuje kliknięcia i czeka na zmiany DOM, których nie ma w surowym HTML.
- **Beautiful Soup** - odczytuje HTML katalogu i szczegółów oraz wybiera elementy i atrybuty.
- **requests / klient HTTP** - pobiera surowy HTML oraz niezależnie odczytuje wykryte źródło JSON do kontroli wyniku.
- **JSON i CSV** - JSON zachowuje typy liczbowe i `null`; CSV jest wygodny do przeglądania i importu do arkuszy.
- **Matplotlib** - generuje histogramy i wykresy pudełkowe.
- **unittest** - testuje parser, normalizację, analizę i scenariusze HTTP/przeglądarkowe.

Playwright wybrano zamiast samego pobierania HTML, ponieważ katalog i szczegóły są renderowane po stronie przeglądarki, a część atrybutów staje się widoczna dopiero po interakcji.

2. Strona WWW

Serwis „Wędkarski Raj” składa się z sześciu podstron:

- `index.html` strona główna z menu, wyróżnionymi produktami i stopką;
- `catalogue.html` katalog 400 produktów;
- `product.html` szczegóły produktu wskazywanego przez parametr `id` w adresie;
- `top_picks.html` trzy najwyżej oceniane produkty;
- `contact.html` informacje kontaktowe;
- `404.html` strona błędu.

Dane wszystkich produktów znajdują się w `www/products.json`. Skrypt w `www/products.js` pobiera je przez `fetch` i tworzy elementy strony w DOM. Katalog pokazuje początkowo 30 produktów; przycisk „Załaduj więcej” symuluje asynchroniczne doładowywanie pozostałych rekordów. Karta produktu zawiera link do szczegółów. Szczegóły są dynamicznie wstawiane do kontenera, a dodatkowe atrybuty są schowane w panelu rozwijanym. Kolejność atrybutów jest losowana po każdym przeładowaniu.

Wybrane utrudnienia

1. Ceny zapisane w różny sposób i różnych walutach
2. Braki wartości w dwóch różnych polach
3. Niespójne formaty dat
4. Atrybuty produktu widoczne dopiero po kliknęciu przycisku na stronie
5. Losowa kolejność atrybutów w karcie produktu

3. Parser

Parser etapu 5.0 używa Playwright/Edge do pobrania dynamicznego katalogu. Czeka na pojawienie się kart, następnie klika doładowanie aż przycisk zniknie, a po uzyskaniu listy odwiedza stronę każdego produktu i

otwiera panel dodatkowych informacji. Znormalizowane dane zapisuje do JSON i CSV. Przy nieudanej próbie stosuje ograniczony retry z opóźnieniami 1, 2 i 4 sekundy; zapisuje diagnostyczny HTML i zrzut ekranu. Minimalny odstęp między żądaniami do serwisu wynosi 0,5 sekundy.

Wynik ma 23 kolumny: 22 atrybuty produktów i URL. W polach wyjściowych zastosowano aliasy `marka` na `producent`, `ocena_srednia` na `ocena` i `aktywny` na `dostepnosc`. Identyfikatory (id, SKU, EAN) pozostają tekstem, wartości liczbowe są normalizowane do `int` lub `float`, a braki do `null` w JSON.

Selektory i uzasadnienie

Zastosowanie	Selektory / metoda	Uzasadnienie
Karty katalogu	#listaProduktow article	Identyfikator kontenera i semantyczny element karty ograniczają wybór do kart katalogu.
Link do szczegółów	a[href*="product.html?"]	Wybór odnośnika po celu nawigacji, a nie po jego pozycji w karcie. Id produktu jest następnie sprawdzany w URL.
Nazwa, kategoria, opis, cena na karcie	.card-title, p.text-muted, .card-text, p.fw-bold	Klasy odpowiadają rolom/typom treści występującym w DOM serwisu.
Kontener strony szczegółów	#szczegolyProduktu	Unikalny kontener szczegółów zapobiega pomyleniu ich z elementami katalogu.
Panel szczegółów	#demo.show	Stan show potwierdza, że zwijane informacje zostały faktycznie otwarte.
Dodatkowe atrybuty	Pary dt i sąsiednie dd, mapowane po tekście etykiety	Działa niezależnie od losowej kolejności atrybutów; nie polega na numerze pola.
Ładowanie kolejnych kart	#pokazWiecej button, spinner w #pokazWiecej, liczba #listaProduktow article	Parser czeka na zmianę stanu i wzrost liczby elementów, a nie na arbitralny czas.

Ocena odporności selektorów

Bardziej odporne na zmiany wyglądu:

- odczyt atrybutów przez etykiety `dt/dd`, ponieważ zmiana kolejności lub kolorów nie zmienia znaczenia etykiety;
- lokalizowanie produktu po jego identyfikatorze i URL, zamiast po kolejności karty;
- selektory oparte o identyfikatory kontenerów, o ile autor zachowa ich znaczenie i unikalność;
- oczekiwanie na widoczność panelu i przyrost liczby kart, które reagują na stan strony, a nie na stały czas animacji.

Mniej odporne:

- `.card-title`, `.card-text`, `.fw-bold`, `p.text-muted` i `p.h3` - zależą częściowo od klas Bootstrap i struktury HTML; zmiana klas lub przeniesienie treści wymaga aktualizacji selektorów;
- `#demo.show` i `button[data-bs-target="#demo"]` - zależą od konkretnego identyfikatora i mechanizmu Bootstrap collapse;
- podział tekstu kategorii i producenta separatorem „·” oraz REGEX dla ceny, stanu i oceny.

Selektory są dopasowane do istniejącego serwisu, a nie do dowolnej witryny. Test przeglądarkowy dodatkowo potwierdza, że zmiana kolejności atrybutów nie zmienia wyników.

4. Kontrola jakości danych

- surowy HTML katalogu zawierał **0 kart**; po wykonaniu JavaScriptu DOM początkowo zawierał **30**, a po **13 doładowaniach** - **400 produktów**;
- parser odwiedził **400 stron szczegółów** i otworzył **400 paneli**;
- przed deduplikacją było 400 rekordów, usunięto 0 duplikatów, po deduplikacji pozostało 400;
- braki: `waga_g` - **80 (20%)**, `kolor` - **80 (20%)**; wszystkie pozostałe 21 kolumn bez braków;
- kolumny liczbowe (`cena`, `ocena`, `liczba_opinii`, `waga_g`, `dlugosc_cm`, `stawka_vat`, `stan_magazynowy`) mają w JSON-ie rzeczywiste typy liczbowe;
- kontrola niezależnego JSON-u porównała **9200 pól** i wykazała **0 różnic**; nie odrzucono żadnych nieprawidłowych wartości;

- IQR wskazał m.in. 3 wysokie ceny PLN, 43 masy, 43 długości, 99 stawek VAT 8% i 54 wysokie stany magazynowe. Wartości są zgodne ze źródłem i nie zostały automatycznie usunięte.

Wynik nie pokazuje błędu typu `129900` zamiast `1299`. Nietypowe wartości są zachowane, ponieważ niezależne porównanie potwierdziło ich zgodność ze źródłem. To rozróżnia obserwację odstającą statystycznie od błędu parsera.

5. Statystyki, wykresy i wnioski

Zakres i sposób liczenia

Statystyki obliczono dla 400 rekordów. Ceny podzielono na grupy walutowe: PLN, EUR, GBP, USD i CZK ponieważ wartości w różnych walutach nie są bezpośrednio porównywalne. Waga ma 320 obserwacji liczbowych; pozostałe cechy poniżej mają po 400. Kwartyle wyznaczono metodą `inclusive`. Jeśli każda wartość występuje tylko raz, moda nie występuje i jest zapisana jako „brak”.

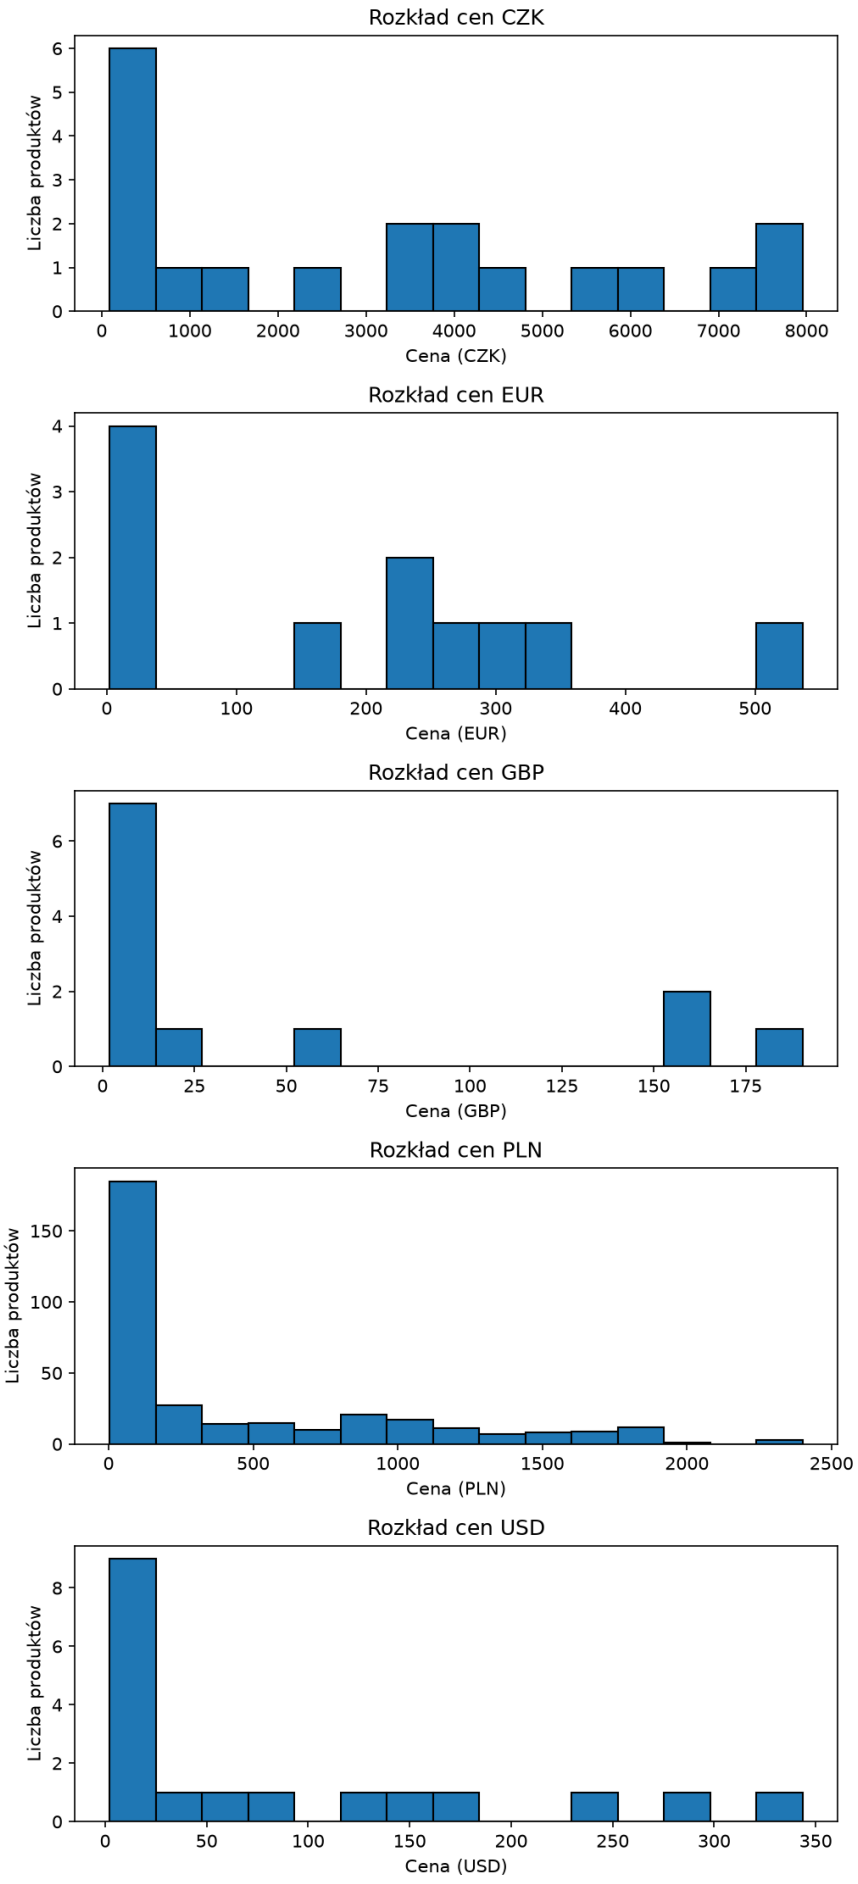
Statystyki cech liczbowych

Cecha / waluta	n	Średnia	Mediana	Moda	Q1	Q3	Minimum	Maksimum
Cena (PLN)	340	451,65	90,45	19,90; 27,90	31,68	820,00	4,00	2399,90
Cena (EUR)	11	193,87	237,38	brak	6,76	298,82	2,31	536,66
Cena (GBP)	12	53,42	10,00	brak	6,68	82,31	1,96	190,50
Cena (USD)	18	89,22	33,41	10,10	10,10	151,20	2,25	343,54
Cena (CZK)	19	3158,00	3519,00	91,00	388,50	4982,50	91,00	7954,00
Ocena	400	4,00	4,00	3,90	3,50	4,50	3,00	5,00
Liczba opinii	400	190,50	191	22, 38, 41, 48, 56, 69, 214, 256	83	282	1	400
Waga (g)	320	923,29	209	9	24	665,50	1	11456
Długość (cm)	400	86,74	16	10	9	126,50	2	418
Stawka VAT (%)	400	19,29	23	23	23	23	8	23
Stan magazynowy	400	18,28	5	0	1	20	0	120

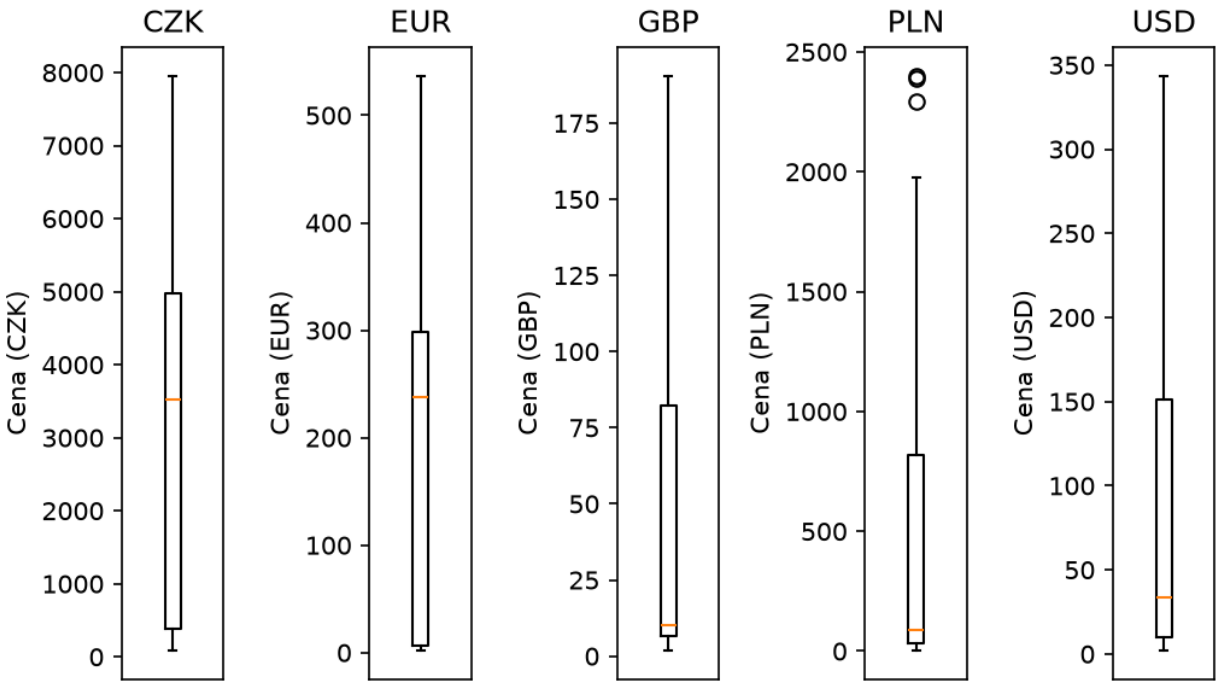
Średnie ceny EUR, GBP i CZK opierają się na małych grupach (11–19 produktów). W PLN średnia jest znacznie wyższa od mediany, co wynika z kilku drogich produktów. Podobnie średnia masy i długości przewyższa medianę: w katalogu są produkty o bardzo różnych gabarytach.

Histogram i wykres pudełkowy

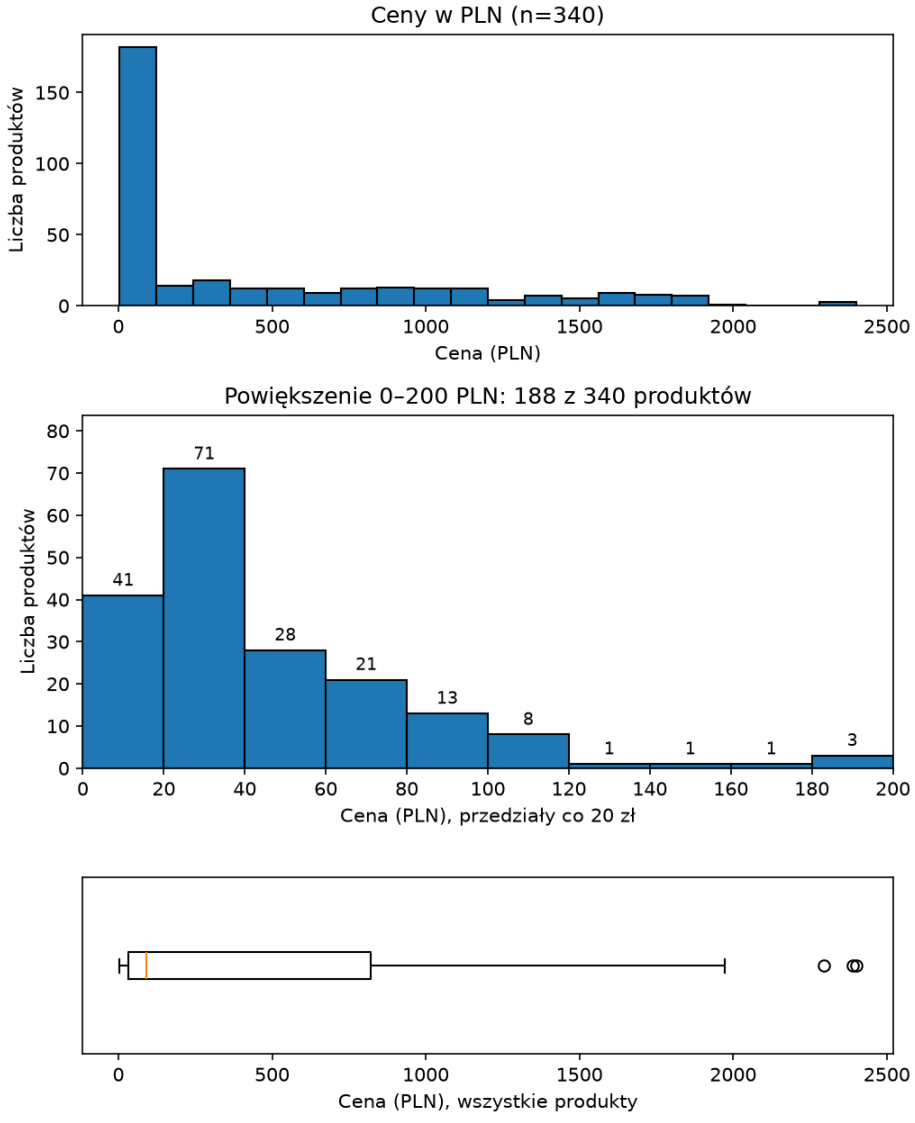
Poniższe wykresy zostały wygenerowane przez skrypt analizy 5.0. Rozkłady cen są przedstawione osobno według waluty.



Histogram cen produktów w podziale na waluty



Wykres pudełkowy cen produktów w podziale na waluty



Zestawienie

Histogram pokazuje koncentrację wielu produktów w niższych przedziałach cenowych i długi prawy ogon. Wykres pudełkowy uwidacznia kilka drogich obserwacji w PLN, które reguła 1,5 IQR oznaczyła jako odstające. Nie są one automatycznie usuwane: porównanie z niezależnym źródłem potwierdziło te same wartości.

Korelacja

Sprawdzono korelację Pearsona między stanem magazynowym a liczbą opinii:

- liczba par: **n = 400**;
- współczynnik: **r = 0,079**;
- interpretacja: **bardzo słaba dodatnia współzmienność**.

Nie ma tu wyraźnego związku liniowego. Merytorycznie słaba korelacja jest wiarygodna: bieżący zapas produktu nie musi odzwierciedlać historycznej liczby opinii. Wynik nie dowodzi jednak braku związku przyczynowego. Dane pochodzą z katalogu demonstracyjnego, a obserwacyjna korelacja nie pozwala na wnioskowanie o wpływie zapasu na opinie.

Wniosek

Test potwierdza poprawność ekstrakcji w aktualnej wersji strony i dla badanego zbioru: dynamiczne renderowanie wymagało pracy na DOM, a parser prawidłowo obsłużył doładowanie, strony szczegółów, losową kolejność atrybutów, brakujące wartości i typy liczbowe. Niezależne porównanie wszystkich pól z JSON-em nie wykazało rozbieżności. Parser zgłaszałby różnice lub błędne wartości przed eksportem; w tym przebiegu żadna korekta danych nie była potrzebna.

6. Porównanie surowego HTML z drzewem DOM

Etap obserwacji	Liczba kart produktów
Surowy HTML pobrany bez przeglądarki	0
DOM po wykonaniu JavaScriptu, przed doładowaniem	30
DOM po zakończeniu doładowywania	400

Różnica wynika z działania serwisu: surowy dokument zawiera strukturę strony i skrypt, natomiast produkty są wstawiane do DOM dopiero po pobraniu JSON-u przez JavaScript. Z tego powodu parser wykorzystuje Playwright/Edge do ekstrakcji DOM.

Niezależna kontrola pobrała wykryte w ruchu sieciowym źródło JSON, ale JSON nie uzupełnia danych DOM i nie zastępuje odwiedzania stron szczegółów. Służy tylko do porównania. W przebiegu porównano 9200 pól i nie znaleziono różnic.

7. Wyniki

Pełny przebieg zakończył się bez ponowień. Parser zarejestrował 816 żądań przeglądarki do serwisu, zachowując minimalny odstęp 0,5 sekundy. Czas parsowania DOM wyniósł 707,766 s, a pobrania i normalizacji JSON 0,031 s. Udało się poprawnie pobrać wszystkie wpisy ze strony sklepu.